

AULA PRÁTICA DE LABORATÓRIO · EDGE AI

Como Ensinar Inspeção Visual Automática de Qualidade com Edge AI

Francisco Lima

Turma técnica/superior com Python básico · 3 horas · duplas em laboratório

Quantas latas com defeito você vê?



Uma esteira não espera o inspetor

1,9

latas por segundo

passando na frente da câmera

40%

com defeito

no vídeo de teste: amassada, sem
rótulo, sem cor

0

pausas na linha

a decisão tem que sair antes da próxima
lata

E se um computador do tamanho de um cartão, **sem internet e sem placa de vídeo**, decidisse sozinho quais latas tirar da linha?

1 · O DESAFIO PROPOSTO

O que a fábrica pediu

Um sistema **embarcado na Raspberry Pi 5** que inspecione as peças em movimento e separe as defeituosas **sem parar a linha**.

VER

Capturar as latas em movimento na esteira

DECIDIR

Classificar cada lata: conforme ou não conforme

EM TEMPO REAL

Decisão antes da próxima lata, sem interromper o fluxo

AGIR

Sinalizar a reprovada por saída digital (GPIO ou relé)

REGISTRAR

Guardar imagens anotadas de cada não conformidade

NA BORDA

Rodar na placa, sem depender de nuvem

1 · A SOLUÇÃO APRESENTADA

Do quadro da câmera ao sopro da lata



Ver e decidir

YOLO26n ajustado com 4 classes · mAP50 0,93

Tempo real

~67 ms por imagem na Pi 5 (NCNN): folga de 8× por lata

Agir e registrar

Pulso no GPIO 17 · CSV por lata · foto de cada defeito

Resultado no vídeo de teste

160 latas contadas · 96 conformes · 64 sopradas

Entrega

API HTTP (JSON e PNG) em Docker amd64 + arm64

2 · OBJETIVOS

Ao final desta aula, vocês serão capazes de...

Explicar por que processar na borda e não na nuvem

Executar um detector de defeitos dentro de um container Docker

Interpretar a resposta do modelo: caixa, classe e confiança

Comparar a velocidade do modelo em formatos diferentes

Decidir se o sistema aguenta a linha, com dados

3 · COMO VAMOS APRENDER

Mão na massa, em duplas, com um problema real

Projeto real

Toda a aula responde a uma pergunta da fábrica (PBL)

Piloto e navegador

Um digita, o outro confere.
Troca a cada 25 min

Degraus

Cada etapa tem um checkpoint visível. Ninguém avança no escuro


Vota, discute, vota

Quizzes com Peer Instruction

Aula expositiva pura: **1,5× mais reprovação** que aprendizagem ativa (Freeman et al., PNAS 2014, 225 estudos).

3 · CONCEITO

Edge AI: o modelo vai até a máquina



Latência

Sem ida e volta à internet: a decisão sai na hora


Sem depender da rede

Se a internet cair, a linha continua inspecionando

Privacidade e custo

As imagens não saem da fábrica e não há mensalidade de nuvem

O que o modelo devolve para cada lata



Caixa

onde a lata está

Classe

boa · amassada · sem
rótulo · sem cor

Confiança

de 0 a 1: quanto o modelo
tem certeza

3 · SEQUÊNCIA DA AULA

180 minutos, do problema à decisão



■ Expositiva curta ■ Laboratório guiado ■ Projeto em dupla ■ Erro como conteúdo

Mais da metade do tempo é mão na massa. A teoria entra quando a prática precisa dela.

Dois comandos e o detector está no ar

Degrau 1 · subir

```
docker compose up -d
```

Degrau 2 · detectar

```
navegador → localhost:8000/docs
```

Envia uma foto da esteira e recebe a resposta em **JSON** e em **imagem marcada**.

```
"classe": "amassada",  
"confianca": 0.68,  
"conforme": false  
  
"resumo": { "total": 6,  
  "conformes": 4,  
  "nao_conformes": 2 }
```

4 · CHECK DE COMPREENSÃO

Uma lata veio com "confiança 0,68". O que isso significa?

A 68% das latas estão boas

B O modelo tem certeza moderada sobre essa lata


C A lata está 68% amassada

D A imagem tem 68% de qualidade


Vota sozinho → discute com a dupla → vota de novo.

O mesmo modelo, velocidades diferentes

Notebook (Intel i5) — medido na aula



Raspberry Pi 5 (ARM) — referência oficial



Lição: meça no hardware alvo

No notebook, o NCNN perde. Na Raspberry, ganha 4,5x. O número do PC não vale para a placa.

Próxima lata a cada

525 ms

Decisão em

67 ms

→ folga de

8x

3 · DESAFIO DA DUPLA

Vocês são o controle de qualidade

1

Testem 3 limiares

confiança mínima $0,25 \cdot 0,5 \cdot 0,8$ em 20 imagens

2

Contem os erros

defeitos que passaram $\times$ latas boas descartadas

3

Decidam

"Aprovamos para a linha?" Com o limiar e a justificativa

Não existe limiar perfeito: **qual erro custa mais caro para a fábrica?**

5 · DÚVIDAS E ERROS COMUNS

O erro é parte da aula

Build não termina

Imagem já montada antes da aula · `docker images`

Porta ocupada

`docker ps` · trocar a porta no compose

Modelo não carrega

Ler o log: `docker compose logs`

Latência alta

Vira o gancho do Degrau 3: formato e tamanho

Cada dupla traz um erro. Resolvemos 2 ou 3 no projetor, mostrando **como diagnosticar**.

Como a dupla é avaliada

CRITÉRIO DA RUBRICA	PESO
Container no ar	20%
Uso dos dois endpoints	20%
Leitura dos resultados	20%
Análise de desempenho	20%
Decisão técnica justificada	20%

Durante a aula

Quizzes relâmpago · checkpoints dos degraus · ticket de saída com 2 perguntas

4 níveis por critério: insuficiente → avançado. A rubrica é entregue no início.

O que conquistamos hoje

- ✓ Explicamos por que a decisão acontece na borda
- ✓ Colocamos um detector de defeitos no ar com Docker
- ✓ Lemos caixa, classe e confiança
- ✓ Medimos e comparamos formatos do modelo
- ✓ Decidimos, com dados, se o sistema aguenta a linha

Edge AI é levar o modelo até a máquina, do tamanho que a máquina aguenta.

7 · PRÓXIMOS PASSOS

Para onde vamos

Próxima aula

Criar o próprio dataset: capturar, anotar e treinar o YOLO

Desafio opcional

Alerta MQTT a cada lata reprovada, ou modelo em INT8 medindo ganho e perda

Leitura

Guia Ultralytics para Raspberry Pi e exportação de modelos

github.com/geanusksama/inspecao-latas