

PLANO DE AULA

CURSO		MÓDULO	CÓDIGO
Inteligência Artificial Aplicada (presencial)		Específico	IAE-VCE
UNIDADE CURRICULAR	CARGA HORÁRIA PREVISTA	DOCENTE	TURMA
Visão Computacional Embarcada (Edge AI)	3 h (180 min) – laboratório	Francisco Lima	A definir
OBJETIVO DA UNIDADE CURRICULAR			
Objetivo: Proporcionar a aquisição de capacidades técnicas relativas à implantação de sistemas de visão computacional embarcados, promovendo a inspeção automática de produtos em linha de produção por meio de modelos de detecção de objetos executados na borda (Edge AI), em container e com integração via API, bem como o desenvolvimento de capacidades sociais, organizativas e metodológicas adequadas a diferentes situações profissionais.			
Público-alvo: estudantes de nível técnico ou superior com conhecimentos básicos em Python.			

FUNDAMENTOS TÉCNICOS E CIENTÍFICOS OU CAPACIDADES TÉCNICAS

1. Identificar os elementos de uma detecção de objetos: caixa delimitadora, classe e confiança (Lembrar)
2. Descrever as etapas de criação e operação de um sistema de inspeção: dados, anotação, treino, exportação e linha de produção (Entender)
3. Explicar as vantagens do processamento na borda (Edge AI) em relação à nuvem (Entender)
4. Preparar o ambiente de execução da aplicação de inferência em container Docker (Aplicar)
5. Utilizar API HTTP de inferência com retorno em JSON e em imagem anotada (Aplicar)
6. Interpretar os resultados da inferência para classificar peças como conformes ou não conformes (Analisar)
7. Comparar o desempenho do modelo em diferentes formatos de inferência (Analisar)
8. Avaliar a viabilidade de operação em tempo real no hardware embarcado (Avaliar)
9. Propor melhorias para a solução embarcada (Criar)

Entre parênteses: nível da Taxonomia de Bloom revisada (Anderson; Krathwohl, 2001).

CAPACIDADES SOCIAIS, ORGANIZATIVAS E METODOLÓGICAS

1. Demonstrar atenção a detalhes
2. Demonstrar capacidade de comunicação com profissionais de diferentes áreas e especialidades
3. Demonstrar capacidade de organização
4. Demonstrar raciocínio lógico na organização das informações
5. Demonstrar visão sistêmica
6. Seguir método de trabalho
7. Trabalhar em equipe

CONHECIMENTOS

1 Visão computacional

- 1.1 Definição e aplicações na indústria
- 1.2 Classificação, detecção e segmentação
- 1.3 Elementos da detecção: caixa delimitadora, classe e confiança
- 1.4 Modelos pré-treinados (família YOLO) e ajuste fino

2 Ciclo de criação do modelo (visão geral)

- 2.1 Captura de imagens a partir de vídeo
- 2.2 Anotação no formato YOLO
- 2.3 Separação em treino e validação
- 2.4 Treino e métricas: precisão, recall e mAP (noções)
- 2.5 Exportação para formato embarcado (NCNN)

3 Inteligência Artificial na borda (Edge AI)

- 3.1 Definição
- 3.2 Borda × nuvem: latência, conectividade, privacidade e custo
- 3.3 Raspberry Pi 5: arquitetura ARM64 e inferência em CPU, sem GPU dedicada
- 3.4 Formatos otimizados e quantização FP16/INT8 (noções)

4 Inspeção na linha de produção

- 4.1 Rastreamento de objetos entre quadros
- 4.2 Linha virtual de decisão e voto da maioria
- 4.3 Saída digital (GPIO) para o soprador
- 4.4 Registro de não conformidades: CSV e imagens anotadas
- 4.5 Leitura do lote por OCR (noções)

5 Containerização

- 5.1 Imagem e container
- 5.2 Dockerfile e docker-compose: porta, volumes e reinício automático
- 5.3 Build multi-arquitetura (amd64 e arm64)

6 Inferência por API HTTP

- 6.1 Pipeline: pré-processamento, inferência e pós-processamento
- 6.2 Endpoint com resposta em JSON
- 6.3 Endpoint com imagem anotada (PNG)
- 6.4 Códigos de status e tratamento de erros

7 Desempenho e tomada de decisão

- 7.1 Latência: mediana, percentil 95 e quadros por segundo
- 7.2 Benchmark no hardware alvo
- 7.3 Falso positivo × falso negativo e o custo de cada erro

ATIVIDADE

SITUAÇÃO DE APRENDIZAGEM: INSPEÇÃO VISUAL AUTOMÁTICA DE QUALIDADE EM LINHA DE PRODUÇÃO

CONTEXTO

Você integra a equipe de engenharia da Refri Vale (empresa fictícia), uma envasadora de refrigerantes em lata. Na última auditoria, o cliente devolveu lotes inteiros porque latas amassadas, sem rótulo e sem pintura chegaram ao mercado. Hoje a inspeção é feita a olho nu por um operador ao lado da esteira, que passa quase 2 latas por segundo, durante todo o turno. A diretoria quer inspecionar 100% das latas, sem parar a linha e sem depender de internet ou de servidores externos. A proposta é instalar, ao lado da esteira, uma Raspberry Pi 5 com câmera, executando um modelo de visão computacional que decida em tempo real se cada lata é conforme ou não conforme, acione o soprador que retira a lata reprovada e registre a imagem de cada defeito para rastreabilidade. Um primeiro protótipo já está pronto e empacotado em container. Antes de aprovar a instalação, a fábrica precisa da sua avaliação técnica: o sistema funciona, aguenta a velocidade da linha e com qual configuração deve ser colocado em operação? Você vai trabalhar em dupla, como numa equipe de comissionamento.	
MOTIVAÇÃO E RELEVÂNCIA	A inspeção manual é lenta, cara e sujeita à fadiga do inspetor, e produtos defeituosos chegam ao cliente final. A inspeção automática embarcada verifica 100% das peças com velocidade, precisão e rastreabilidade, reduzindo desperdício, retrabalho e devoluções, alinhada aos princípios da Indústria 4.0 e ao controle estatístico de qualidade (CEP/SPC).
DESCRIÇÃO DO PROBLEMA	Latas passam por uma esteira em velocidade constante, e os defeitos precisam ser identificados antes do empacotamento. O sistema deve capturar imagens das latas em movimento, executar a inferência com um modelo de detecção de defeitos (lata boa, amassada, sem rótulo e sem cor), sinalizar as reprovadas por saída digital (GPIO ou relé) e registrar imagens anotadas das não conformidades.
CARACTERÍSTICAS DO AMBIENTE	Fábrica com ruído e vibração da esteira · variação de iluminação · reflexo e brilho nas superfícies metálicas das latas · velocidade da esteira entre 0,1 e 0,5 m/s · temperatura entre 18 °C e 35 °C · hardware embarcado sem GPU dedicada (Raspberry Pi 5).
O QUE A DUPLA DEVE ENTREGAR	1. O sistema de inspeção em execução no container, respondendo pela API. 2. A classificação de imagens reais da esteira em conformes e não conformes, com a leitura de classe e confiança. 3. A medição de latência do modelo e a comparação com a velocidade da linha. 4. A ficha de decisão técnica: limiar de confiança escolhido, erros observados e parecer "aprovo / não aprovo para a linha", com justificativa.
APLICABILIDADE	Autopeças e componentes eletrônicos · alimentos e bebidas embalados · dispositivos médicos · vidro plano e cerâmica · eletrodomésticos · gráficas e embalagens · indústria farmacêutica.

AVALIAÇÃO FORMATIVA: LABORATÓRIO GUIADO EM DEGRAUS	
CONTEXTO	Antes de decidir, a equipe precisa conhecer o protótipo. Em dupla (piloto e navegador), você sobe o sistema, envia imagens da esteira e mede o desempenho, avançando por degraus com um checkpoint visível ao professor ao fim de cada um.
ENTREGAS (CHECKPOINTS)	Degrau 1: container no ar e serviço respondendo · Degrau 2: resposta em JSON e imagem anotada · Degrau 3: tabela de latência PyTorch × NCNN · Quizzes relâmpago 1 e 2. Registro F (formativo) no instrumento de avaliação.

AVALIAÇÃO SOMATIVA: FICHA DE DECISÃO TÉCNICA
--

CONTEXTO	A diretoria da Refri Vale precisa de um parecer objetivo. Com 20 imagens de teste, a dupla testa os limiares de confiança 0,25, 0,5 e 0,8, conta os defeitos que passariam e as latas boas que seriam descartadas, e decide se o sistema pode ser instalado na linha.
ENTREGA	Ficha de decisão técnica preenchida e apresentada em até 1 minuto, com dados (limiar, erros e latência). Registro S (somativo) no instrumento de avaliação.

METODOLOGIA ATIVA E JUSTIFICATIVA	
• Aprendizagem Baseada em Projetos (PBL): a aula inteira responde a um problema industrial real, com um entregável concreto: a decisão técnica da dupla sobre colocar ou não o sistema na linha. • Programação em pares (piloto e navegador): um digita e o outro confere; os papéis trocam a cada bloco de 20 a 25 minutos. • Laboratório guiado em degraus: cada etapa termina num checkpoint visível (container no ar, primeira resposta, tabela de latência). • Instrução por pares (Peer Instruction): nos quizzes, cada estudante vota, discute com a dupla e vota de novo. Justificativa: uma meta-análise de 225 estudos em ciências e engenharia (Freeman et al., 2014) mostrou que estudantes em aulas apenas expositivas tiveram 1,5 vez mais chance de reprovação do que em aulas com aprendizagem ativa. O público tem só Python básico: ver a lata defeituosa ser identificada dá sentido aos conceitos, sem exigir matemática. As duplas equilibram turmas heterogêneas, e os erros do laboratório viram conteúdo da aula.	

REQUISITOS TÉCNICOS E PEDAGÓGICOS	
INFRAESTRUTURA (POR DUPLA)	Computador com Docker, 8 GB de RAM, 15 GB livres, navegador e terminal; imagem <i>inspecao-latas</i> já montada; repositório do projeto clonado; 20 imagens de teste da esteira
INFRAESTRUTURA (SALA)	Projektor; computador do professor com o mesmo ambiente; rede local (a aula funciona sem internet); kit Raspberry Pi 5 com relé ou LED no GPIO 17 para demonstração (opcional)
CONHECIMENTO PRÉVIO	Necessário: Python básico (variáveis, listas, dicionários, funções) e uso básico do terminal. Não necessário: matemática de redes neurais, treino de modelos, Docker avançado.
NIVELAMENTO	Folha impressa de comandos; quem não usa terminal pode fazer tudo pelo navegador (Swagger)

RECURSOS E MATERIAIS DE APOIO (VERIFICAR ANTES DA AULA)
☐ Imagem Docker montada e testada em todas as máquinas · ☐ Repositório e imagens de teste em cada máquina ☐ Vídeo da esteira e slides no computador do professor; projetor testado ☐ Folhas impressas: comandos, instrumento de avaliação e ficha de decisão da dupla ☐ Quizzes 1 e 2 prontos (cartões A/B/C/D ou formulário) · ☐ Máquina reserva e gravação da demonstração (plano B) ☐ (Opcional) Kit Raspberry Pi 5 montado

INSTRUMENTO DE REGISTRO DE AVALIAÇÃO

Natureza dos critérios	Fundamentos técnicos e científicos ou capacidades técnicas	Critérios de avaliação				Alunos							
			Crítico		Desejável								
		0	NÃO atingiu	1	Atingiu								
		F	Formativa	S	Somativa								
Competências técnicas	1. Identificar os elementos de uma detecção: caixa, classe e confiança	Identificou caixa, classe e confiança na resposta do modelo				F							
						S							
		Relacionou a cor de cada caixa à classe da lata				F							
						S							
	2. Descrever as etapas de criação e operação do sistema de inspeção	Descreveu na ordem o ciclo: captura, anotação, treino, exportação e operação na linha				F							
						S							
	3. Explicar as vantagens do processamento na borda em relação à nuvem	Explicou ao menos duas vantagens da borda para a linha de produção				F							
						S							
		Citou uma limitação do hardware embarcado				F							
						S							
	4. Preparar o ambiente de execução em container Docker	Executou o container e obteve resposta do serviço (/saude)				F							
						S							
		Explicou a função da porta exposta e do reinício automático				F							
						S							
	5. Utilizar API HTTP de inferência com retorno em JSON e em imagem anotada	Obteve a resposta em JSON do endpoint de detecção				F							
						S							
		Obteve a imagem anotada do endpoint de imagem				F							
						S							
		Provocou e interpretou um erro (arquivo inválido, HTTP 400)				F							
						S							
	6. Interpretar os resultados para classificar peças como conformes ou não conformes	Classificou corretamente as latas conformes e não conformes de uma imagem				F							
						S							
		Identificou um falso positivo ou um falso negativo				F							
						S							
	7. Comparar o desempenho do modelo em diferentes formatos de inferência	Mediu a latência do modelo em PyTorch e em NCNN				F							
						S							
		Explicou por que o resultado no PC difere do resultado na Raspberry Pi 5				F							
						S							
	8. Avaliar a viabilidade de operação em tempo real no hardware embarcado	Relacionou a latência medida com o intervalo entre as latas na esteira				F							
						S							
		Escolheu e justificou o limiar de confiança considerando o custo dos erros				F							
						S							
	9. Propor melhorias para a solução embarcada	Propôs uma melhoria viável (quantização, alerta MQTT ou nova classe)				F							
						S							

PLANO DE AULA (Estratégia de ensino e aprendizagem) – Sequência didática

Tempo	Conhecimentos	Estratégias	Mediação (perguntas mediadoras)
0–15 min	Apresentação da aula e do problema real da linha de produção	Vídeo da esteira com latas defeituosas; apresentação dos objetivos; formação das duplas e dos papéis	Quantas latas com defeito vocês viram? Por que um inspetor humano falha nessa tarefa?
15–35 min	1 Visão computacional · 2 Ciclo do modelo · 3.1–3.2 Edge AI	Exposição dialogada curta com projetor; visão geral do ciclo do modelo em uma figura; Quiz relâmpago 1 (Peer Instruction)	O que o modelo devolve para cada lata? Por que não mandar as imagens para a nuvem?
35–55 min	5 Containerização	Hands-on, Degrau 1: subir o container e conferir o serviço; leitura guiada do Dockerfile	O que é uma imagem e o que é um container? Por que o sistema precisa voltar sozinho após uma queda?
55–80 min	6 Inferência por API HTTP	Hands-on, Degrau 2: enviar imagens aos endpoints de JSON e de imagem anotada; troca de papéis na dupla	Como ler classe, confiança e caixa no JSON? O que acontece se enviarmos um arquivo que não é imagem?
80–90 min	Intervalo		
90–115 min	3.3–3.4 Hardware e formatos · 7.1–7.2 Desempenho	Hands-on, Degrau 3: benchmark PyTorch × NCNN; comparação com a referência da Raspberry Pi 5; Quiz relâmpago 2	Por que o mesmo modelo tem velocidades diferentes? O resultado do notebook vale para a placa?
115–145 min	1.3 Confiança e limiar · 7.3 Custo dos erros	Desafio da dupla (PBL): testar limiares de 0,25, 0,5 e 0,8 em 20 imagens e preencher a ficha de decisão	Qual erro custa mais caro para a fábrica: deixar passar defeito ou descartar lata boa?
145–160 min	Gestão de dificuldades	Cada dupla traz o erro que encontrou; resolução de 2 a 3 casos no projetor	Onde procurar a causa: no log, na porta, no modelo ou na imagem enviada?
160–175 min	4 Inspeção na linha · Síntese	Demonstração do professor: inspeção do vídeo com rastreo, linha virtual, sopro no GPIO (LED), registro em CSV e leitura do lote; retomada coletiva dos objetivos; 3 duplas apresentam a decisão em 1 minuto	Como a decisão de uma imagem vira a decisão sobre uma lata em movimento? Quais objetivos atingimos?
175–180 min	Próximos passos	Ticket de saída (2 perguntas); próxima aula e desafios opcionais (MQTT, INT8)	Qual frase define Edge AI? Que número do JSON você olharia primeiro para confiar numa detecção?

ELABORAÇÃO	DATA	APROVAÇÃO	DATA
Francisco Lima	04 / 10 / 2026		/ /

Referências: ANDERSON, L. W.; KRATHWOHL, D. R. *A Taxonomy for Learning, Teaching, and Assessing*. Longman, 2001. · FREEMAN, S. et al. Active learning increases student performance in science, engineering, and mathematics. *PNAS*, v. 111, n. 23, p. 8410–8415, 2014. · MAZUR, E. *Peer Instruction: A User's Manual*. Prentice Hall, 1997. · ULTRALYTICS. Raspberry Pi guide. docs.ultralytics.com/guides/raspberry-pi (acesso em 04/10/2026).